

Геометрический подход к оценке сложности данных на основе генеративных диффузионных моделей

Черноусов Данила

Консультант: Грабовой А.В., к.ф.-м.н.

Кафедра интеллектуальных систем, МФТИ

2026

Постановка проблемы

Проблема

Размер выборки N - плохая оценка сложности

Хотим:



- ▶ Учитывать связи между объектами
- ▶ Выполнение ряда свойств
- ▶ Гипотеза: сложность выборки ограничена сверху

Новизна

- ▶ Первая мера сложности учитывающая связи между объектами
- ▶ Доказанные теоремы позволяют строить произвольные меры

Зачем измерять сложность данных:

- ▶ **Интерпретируемость** — предсказание качества модели по характеристикам обучающей выборки, а не только по её размеру
- ▶ **Активное обучение** — обучающие батчи с учётом сложности батча
- ▶ **Оценка разнообразия** — сравнение выборок одного размера, но разного содержания

Траекторное вложение

ОДУ вероятностного потока:

$$\frac{dz}{dt} = -\dot{\sigma}(t) \sigma(t) s(z, t), \quad z(0) = x$$

где $s(x, t) = \nabla_x \log p_t(x)$ — скор-функция

Траекторное расстояние:

$$D(x_i, x_j)^2 = \int_0^1 \|z_{x_i}(t) - z_{x_j}(t)\|^2 w(t) dt = \int_0^1 \|z_{x_i}(t) - z_{x_j}(t)\|^2 d\mu_w(t)$$

где $w(t) = \text{Beta}(t; \alpha, \beta)$ — плотность вероятности, $d\mu_w(t) = w(t) dt$ — индуцированная мера

$$D(x_i, x_j) = \|z_{x_i} - z_{x_j}\|_{L^2([0,1], \mu_w; \mathbb{R}^D)}$$

Мера сложности

Гауссово ядро: $K_{ij} = \exp(-\lambda D(x_i, x_j)^2)$, $K_{ii} = 1$, $0 \leq K_{ij} \leq 1$

Сложность выборки

$$\mathcal{C}(\mathcal{X}) = \log \det(I + K) = \sum_{k=1}^N \log(1 + \mu_k), \quad \mu_k \text{ — собственные числа } K$$

Интерпретация:

- ▶ Каждое $\log(1 + \mu_k)$ — вклад одного независимого направления в траекторном пространстве
- ▶ $\mu_k \gg 1$ (новое направление): вклад $\approx \log \mu_k$
- ▶ $\mu_k \approx 0$ (избыточная точка): вклад ≈ 0

$\mathcal{C}(\mathcal{X})$ — число независимых семантических направлений в данных

Теорема


Предложенная мера $\mathcal{C}(\mathcal{X}) = \log \det(I + K)$ удовлетворяет:

- 1) Инвариантность к перестановкам
- 2) Липшицевость по выборке
- 3) Субаддитивность: $\mathcal{C}(\mathcal{A} \cup \mathcal{B}) \leq \mathcal{C}(\mathcal{A}) + \mathcal{C}(\mathcal{B})$
- 4) Ограниченная монотонность: $0 < \mathcal{C}(\mathcal{X} \cup \{x\}) - \mathcal{C}(\mathcal{X}) \leq \log 2$

Асимптотическое поведение:

- ▶ N одинаковых объектов: $\mathcal{C} \sim \log N$
- ▶ N различных объектов: $\mathcal{C} \sim N \log 2$


Эксперимент: скорость роста



Синтетическая смесь гауссиан,
 $D = 2$, аналитическая скор-функция

- ▶ N кластеров, по 1 точке:
 $\mathcal{C} \approx N \log 2$
- ▶ Один кластер, $\sigma = 0.1$:
 $\mathcal{C} \approx \log(1 + N)$
- ▶ Один кластер, $\sigma = 1$:
промежуточный рост


Эксперимент: чувствительность к разделению кластеров



$K = 3$ кластера, $N = 30$ точек,
 $D = 2$

- ▶ C растёт с увеличением разделения δ
- ▶ Выходит на плато при полном разделении кластеров ($\delta \gtrsim 5$)
- ▶ На плато: K блочно-диагональна

Эксперимент: MNIST



Предобученная DDPM, ОДУ
вероятностного потока

- ▶ Один класс vs несколько классов
- ▶ C мультикласса растёт быстрее
- ▶ Подтверждает: разнообразные данные $\rightarrow$ большая сложность

Заключение

- 1) Определена мера сложности выборки $\mathcal{C}(\mathcal{X}) = \log \det(I + K)$ на основе траекторных расстояний диффузионной модели
- 2) Доказаны ключевые теоремы
- 3) Установлена интерпретация с точки зрения дифференциальной геометрии
- 4) Проведена экспериментальная проверка на синтетических и реальных данных